

Koopman–JEPA

¿Puede un JEPA aprender operadores dinámicos no triviales?

Informe final del experimento controlado

Septiembre de 2026

Sí, bajo los datos y la receta estudiados: el predictor identifica tres operadores en 10/10 seeds por condición y sigue una familia continua con MAE espectral 0.027. Esto demuestra posibilidad, no necesidad ni superioridad: DMD crudo y PCA+DMD también resuelven este dataset.

1. Pregunta

Buscamos una representación $z_t = f_\theta(x_t)$ y un predictor lineal M tales que

$$Mz_t \approx z_{t+1}.$$

Si $\psi(r_t)$ describe la fase verdadera, K es su operador y el encoder aprende $z \approx A\psi$, la prueba relevante es

$$\boxed{MA \approx AK}.$$

No exigimos $M = K$: el encoder puede elegir otra base. Medimos tanto la acción de M como su espectro restringido al span activo de los centroides latentes.

2. Datos y control causal

El estado oculto tiene cuatro fases $r \in \{0, 1, 2, 3\}$. Cada fase genera una ventana de longitud 128:


$$x_t[\tau] = a_t s_{r_t}(\tau - \delta_t) + b_t + \epsilon_{t,\tau},$$

con amplitud, offset, jitter temporal y ruido independientes. Los mismos bancos de ventanas actuales y futuras se reutilizan en todas las condiciones; sólo cambia el emparejamiento temporal.

Dinámica	Transición	Espectro activo
Estática	$r_{t+1} = r_t$	$\{1, 1, 1\}$
Cíclica	$r_{t+1} = r_t + 1 \text{ (mód 4)}$	$\{-1, i, -i\}$
Independiente	fase futura uniforme	$\{0, 0, 0\}$

Por seed y condición usamos 1024 pares de entrenamiento y 256 de validación. La prueba principal repite 10 seeds. La auditoría verifica marginales idénticos, transiciones correctas y fase perfectamente decodificable; una ventana aislada no revela a qué dinámica pertenece.

3. Arquitectura y supuestos



Se entrena 60 épocas con AdamW. El predictor usa learning rate $4\times$ mayor; el encoder se congela tras la época 3 y el target se actualiza por EMA. La loss agrega regularización de media, varianza y covarianza para evitar colapso.

La dimensión latente 3 coincide con el rango verdadero y el freeze temprano estabiliza el ajuste de M . Ambos son supuestos del resultado, no propiedades generales de JEPA.

4. Resultado principal: tres operadores

Para cada candidato d calculamos

$$E_d = \frac{\|MA - AK_d\|_F}{\|A\|_F}.$$

También comparamos los autovalores de M en el span activo. El criterio fijado antes de correr fue al menos 8/10 seeds correctas por acción y por espectro. La loss no participa en esta decisión.

Dinámica	Acción	Espectro	Error	Margen
Estática	10/10	10/10	0.142	0.806
Cíclica	10/10	10/10	0.068	0.877
Independiente	10/10	10/10	0.015	0.981




Figura 1: Error mediano contra cada candidato. Cada fila usa los mismos marginales observables y un pairing distinto. La diagonal es mínima tanto por acción como por espectro.




Figura 2: Error $\|M^h A - AK^h\|_F / \|A\|_F$. La identificación a un paso es clara; en estática y cíclica el error se acumula con el horizonte.

5. Generalización a una intensidad continua

Interpolamos entre el ciclo C y una transición uniforme U :

$$P_\rho = \rho C + (1 - \rho)U, \quad K_\rho = \rho C, \quad \text{spec}(K_\rho) = \rho\{-1, i, -i\}.$$

ρ	Acción	Espectro	Módulo mediano
0.00	10/10	10/10	0.016
0.25	10/10	10/10	0.239
0.50	9/10	9/10	0.476
0.75	8/10	8/10	0.718
1.00	7/10	7/10	0.948





Figura 3: Izquierda: módulo espectral aprendido contra ρ . Derecha: autovalores esperados y aprendidos en el plano complejo.

La calibración continua tiene MAE 0.027, pendiente 0.937, intercepto 0.011 y $R^2 = 0.9998$. El criterio discreto de 8/10 en cada nivel no pasa porque $\rho = 1$ queda en 7/10: algunas seeds eligen el nivel vecino por un sesgo contractivo. Se conservan ambas lecturas sin crear un nuevo umbral post-hoc.

6. £JEPA es lo que hace el trabajo?

Comparamos siete métodos sobre la misma familia continua. Esta tabla corresponde a una sola seed de validación: contextualiza el mecanismo, pero no es una comparación confirmatoria multiseed.

Método	MAE espectral	MAE acción	Pendiente
Oracle de fase + OLS	0.000	0.000	1.000
Ventana cruda + DMD	0.022	0.020	0.949
PCA-3 + DMD	0.011	0.011	0.975
CNN aleatoria + DMD	0.299	0.137	0.391
CNN supervisada + DMD	0.012	0.011	0.968
JEPA + M aprendido	0.197	0.103	0.435
Encoder JEPA + DMD post-hoc	0.029	0.026	0.952

JEPA mejora a la CNN aleatoria, pero DMD crudo y PCA+DMD obtienen menor error. El encoder JEPA con DMD post-hoc mejora mucho al predictor entrenado, lo que sitúa el principal cuello de botella en la optimización conjunta de M . Este dataset no permite afirmar que JEPA sea necesario ni superior.

7. Conclusión exacta

La evidencia sí apoya que este JEPA puede representar una dinámica no trivial y que su espectro responde casi linealmente a la persistencia dinámica, bajo la arquitectura, dimensión latente, freeze, EMA, regularizadores y datos documentados.

La evidencia no apoya recuperación general de Koopman, superioridad sobre métodos lineales, robustez fuera de distribución ni independencia de la receta. La comparación de baselines quedó en una seed de validación y su held-out no se abrió. El estudio se cierra con este alcance; no se atribuye al experimento una conclusión que no fue medida.

Reproducibilidad

El flujo completo está reducido a cinco notebooks ejecutados en `notebooks/`. Las cuatro configuraciones están en `configs/`, el diseño consolidado en `docs/EXPERIMENT.md` y la implementación reutilizable en `src/koopman_jepa/`. Los tests verifican datos, álgebra, entrenamiento y outputs versionados.