

Koopman-JEPA

¿Puede un JEPA aprender operadores dinámicos no triviales?

Control de tres dinámicas y generalización a decaimiento continuo

21 de septiembre de 2026

Respuesta corta: sí, con un límite cuantitativo. El predictor identifica tres dinámicas extremas en 10/10 seeds y calibra una familia de decaimiento con MAE 0.027. La clasificación exacta de cinco niveles no supera el criterio global: el extremo cíclico queda en 7/10.

1. Pregunta

Buscamos una representación $z_t = f_\theta(x_t)$ y un predictor lineal M que satisfagan

$$Mz_t \approx z_{t+1}.$$

Si el encoder aprende $z \approx A\psi$ y K es el operador conocido sobre las variables de fase, la prueba central es

$$MA \approx AK.$$

Esta relación permite que el encoder elija su propia base: no exige que $M = K$, sino que ambos representen la misma dinámica en coordenadas diferentes.

2. Dataset controlado

La variable oculta tiene cuatro fases $r \in \{0, 1, 2, 3\}$. Cada fase produce una ventana de longitud 128:


$$x_t[\tau] = a_t s_{r_t}(\tau - \delta_t) + b_t + \epsilon_{t,\tau},$$

con amplitud, desplazamiento, offset y ruido independientes por ejemplo. Los mismos bancos de ventanas actuales y futuras se reutilizan en tres condiciones; sólo cambia el pairing temporal.

Condición	Pairing	Acción	Espectro activo
Estática	$r_{t+1} = r_t$	conserva fase	$\{1, 1, 1\}$
Cíclica	$r_{t+1} = r_t + 1 \text{ (mód 4)}$	rota fases	$\{-1, i, -i\}$
Independiente	16 pares balanceados	media cero	$\{0, 0, 0\}$

Por seed y condición usamos 1024 pares de train y 256 de validation, ventanas 1×128 y marginales uniformes. Se repiten 10 seeds emparejadas. Así, una diferencia entre predictores sólo puede atribuirse a la transición temporal.

3. Arquitectura



El encoder online usa AdamW con learning rate 10^{-3} ; el predictor usa 4×10^{-3} . El target se actualiza por EMA con momentum 0.90. El encoder se congela después de la época 3 y M continúa hasta la época 60. La loss combina predicción y regularización anti-colapso de media, varianza y covarianza; esa loss no se usa para decidir si el operador fue identificado.

4. Evaluación

Para cada modelo ajustamos la base de fase A y calculamos

$$E_d(M, A) = \frac{\|MA - AK_d\|_F}{\|A\|_F}, \quad d \in \{\text{estática, cíclica, independiente}\}.$$

La dinámica predicha minimiza E_d . Repetimos la clasificación usando los eigenvalues de M restringido al span activo. Una seed sólo cuenta cuando ese span tiene rango 3.

El criterio predeclarado fue al menos 8/10 seeds correctas por condición. Bajo elección aleatoria entre tres operadores, $P(X \geq 8 \mid n = 10, p = 1/3) \approx 0.0034$.

5. Resultado principal

Dinámica	Acción	Espectro	Error	Margen
Estática	10/10	10/10	0.142	0.806
Cíclica	10/10	10/10	0.068	0.877
Independiente	10/10	10/10	0.015	0.981

Las 30 corridas tienen rango activo 3 y probe lineal de fase del 100%.




Figura 1: Error mediano contra cada operador candidato. Las filas son las dinámicas verdaderas y las columnas los candidatos. La diagonal oscura es el mínimo en acción y espectro para las tres condiciones.

La figura descarta una explicación puramente visual. Los marginales son los mismos, pero M cambia con el pairing. Los errores fuera de la diagonal quedan aproximadamente entre 0.85 y 1.58, lejos de los candidatos correctos.

6. Consistencia multi-step




Figura 2: Error $\|M^h A - AK^h\|_F / \|A\|_F$ frente al horizonte.

La condición independiente converge casi a cero desde $h = 2$. En estática el error crece de 0.142 a aproximadamente 0.305 en $h = 8$; en cíclica crece de 0.068 a aproximadamente 0.377. El operador se identifica claramente a un paso, pero los pequeños errores se acumulan a horizontes largos.

7. Generalización a dinámica amortiguada

Para pasar de tres operadores separados a una familia continua definimos

$$P_\rho = \rho C + (1 - \rho)U, \quad K_\rho = \rho C, \quad \text{spec}(K_\rho) = \rho\{-1, i, -i\},$$

con $\rho \in \{0, .25, .5, .75, 1\}$. C es el ciclo y U produce una fase futura uniforme e independiente. Las ventanas, los marginales, la arquitectura y la receta permanecen fijos; se entrenan 10 seeds por nivel.

ρ	Acción	Espectro	Módulo mediano
0.00	10/10	10/10	0.016
0.25	10/10	10/10	0.239
0.50	9/10	9/10	0.476
0.75	8/10	8/10	0.718
1.00	7/10	7/10	0.948

El criterio predeclarado exigía al menos 8/10 aciertos por acción y espectro en *cada* fila. El resultado global formal es negativo porque $\rho = 1$ queda en 7/10; no se cambió el corte después de observar los datos.




Figura 3: Error mediano frente a cinco operadores candidatos. Hay una diagonal clara, pero algunas seeds quedan más cerca del nivel inmediatamente inferior.




Figura 4: Izquierda: módulo espectral aprendido frente a ρ . Derecha: autovalores aprendidos y esperados en el plano complejo.

La lectura continua es fuerte: el MAE entre ρ y el módulo mediano es 0.027; la recta de calibración tiene pendiente 0.937, intercepto 0.011 y $R^2 = 0.9998$. El sesgo es contractivo y crece en algunas seeds de $\rho = .75$ y 1. Así, el JEPA aprende el continuo amortiguado en promedio, pero todavía no cuantifica cada nivel con robustez seed-a-seed. El caso $\rho = 1$ usa exactamente los mismos tensores que el ciclo anterior; la diferencia es que ahora compite contra candidatos vecinos como $\rho = .75$.

8. Conclusión y límites

El experimento apoya que un JEPA puede aprender una restricción Koopman no trivial en un sistema sintético controlado. La extensión muestra además que el espectro responde casi linealmente a una tasa dinámica continua, aunque el criterio discreto más estricto no pasa en todas las seeds. No demuestra recuperación general del operador Koopman.

- Sólo hay cuatro estados y la dimensión verdadera del latent es conocida.
- El control conjunto usa validation, no una nueva partición ciega.
- El encoder se congela temprano para estabilizar la optimización.
- Los rollouts estático y cíclico acumulan error.
- Sólo se varía una familia de un parámetro con el mismo mapa de observación.
- El predictor muestra un sesgo contractivo que confunde niveles vecinos en algunas seeds.

El próximo paso es repetir la familia K_ρ sobre emisiones nuevas y ciegas, sin retocar la receta con estas mismas 50 corridas. Luego corresponde variar el mapa de observación o el número de fases y reducir el sesgo contractivo sin introducir los eigenvalues verdaderos en la loss.

Reproducibilidad

La extensión está en `notebooks/koopman_decay_generalization.ipynb` y su protocolo en `docs/DECAY_GENERALIZATION_PROTOCOL.md`. El control base permanece en `notebooks/stage3_three_dynamics_control.ipynb`. El repositorio incluye tests automáticos para datos, álgebra, entrenamiento y outputs de notebooks.